



UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY



MODEL DISTRIBÚCIE INTERPUNKČNÝCH
ZNAMIENOK V RÔZNYCH TEXTOCH
DIPLOMOVÁ PRÁCA

2027
FILIP VALÍČEK

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY



MODEL DISTRIBÚCIE INTERPUNKČNÝCH
ZNAMIENOK V RÔZNYCH TEXTOCH
DIPLOMOVÁ PRÁCA

Študijný program: Aplikovaná informatika
Študijný odbor: Informatika
Školiace pracovisko: Katedra aplikovanej informatiky
Školiteľ: doc. RNDr. Mária Markošová, PhD.

Bratislava, 2027
Filip Valíček



Univerzita Komenského v Bratislave
Fakulta matematiky, fyziky a informatiky

ZADANIE ZÁVEREČNEJ PRÁCE

Meno a priezvisko študenta: Bc. Filip Valíček
Študijný program: aplikovaná informatika (Jednoodborové štúdium, magisterský II. st., denná forma)
Študijný odbor: informatika
Typ záverečnej práce: diplomová
Jazyk záverečnej práce: slovenský
Sekundárny jazyk: anglický

Názov: Model distribúcie interpunkčných znamienok v rôznych textoch
Model of punctuation mark distributions in various texts

Anotácia: Študent naprogramuje, alebo použije už naprogramovanú aplikáciu na hľadanie distribúcie interpunkčných znamienok v textoch v rôznych jazykoch. Ak študent použije hotovú aplikáciu, musí k nej doprogramovať v šetko potrebné na analýzu distribúcie a na tvorbu jej modelu. Študent zanalyzuje distribúcie z textov toho istého autora v rôznych časových obdobiach aby zistil, ako sa táto vlastnosť textu mení a nakoľko ostáva stabilná. Navrhne matematický model tejto distribúcie, popr9pade n8jde parametre známeho matematického modelu, ktoré budú čo najlepšie vystihovať nameranú distribúciu. Porovná rôzne textové žánre.

Cieľ: - naprogramovať aplikáciu, alebo doprogramovať potrebné nástroje do aplikácie na analýzu distribúcií interpunkčných znamienok v textoch a vytvoriť matematický model opisujúci získané výsledky

Literatúra: Kulig and others. In narrative texts punctuation marks obey the same statistics as words, Information Sciences
Volume 375, 1 January 2017, Pages 98-113

Vedúci: doc. RNDr. Mária Markošová, PhD.
Katedra: FMFI.KAI - Katedra aplikovanej informatiky
Vedúci katedry: doc. RNDr. Tatiana Jajcayová, PhD.
Dátum zadania: 23.02.2024

Dátum schválenia: 26.11.2025
prof. RNDr. Roman Ďurikovič, PhD.
garant študijného programu

.....
študent

.....
vedúci práce

Abstrakt

Táto diplomová práca sa zaoberá analýzou distribúcie interpunkčných znamienok v slovných sieťach zostavených z literárnych textov v rôznych jazykoch. Práca skúma, ako prítomnosť či neprítomnosť interpunkcie ovplyvňuje štrukturálne vlastnosti sietí susednosti slov. Texty sú reprezentované ako grafy, kde uzly zodpovedajú slovám a hrany vznikajú medzi slovami, ktoré sa v texte vyskytujú bezprostredne za sebou. Na týchto grafoch sú následne skúmané rôzne charakteristiky, ako distribúcia stupňov uzlov, klasterizačný koeficient či hierarchická organizácia siete.

Súčasťou práce je aj návrh a implementácia vlastnej aplikácie, ktorá umožňuje texty spracovať, vytvárať z nich siete a interaktívne porovnávať výsledky pre rôzne jazykové verzie a rôzne nastavenia práce s interpunkciou. Osobitná pozornosť je venovaná porovnaniu grafov vytvorených so započítaním interpunkcie a bez nej. Cieľom práce je prispieť k lepšiemu pochopeniu toho, akú úlohu zohráva interpunkcia v štruktúre textu a nakoľko ovplyvňuje vlastnosti jazykových sietí. Tému som si zvolil preto, že ma zaujíma analýza dát a štatistické zákonitosti, ktoré sa dajú odhaliť aj v prirodzenom jazyku. Zaujímavé na tejto téme je pre mňa najmä to, že aj bežné texty v sebe ukrývajú črty, ktoré možno pomocou vhodných nástrojov zachytiť a porovnávať.

Kľúčové slová: slovná sieť, interpunkcia, rozloženie stupňov, mocninový zákon, Zipf-Mandelbrot, klastrovanie, Python, analýza textu

Abstract

This diploma thesis deals with the analysis of punctuation mark distribution in word networks constructed from literary texts in different languages. The thesis examines how the presence or absence of punctuation influences the structural properties of word adjacency networks. The texts are represented as graphs in which nodes correspond to words and edges are formed between words that occur immediately next to each other in the text. Various characteristics of these graphs are then studied, such as degree distribution, clustering coefficient, and the hierarchical organization of the network.

Part of the thesis is also the design and implementation of a custom application that makes it possible to process texts, build networks from them, and interactively compare results for different language versions and different punctuation settings. Special attention is paid to the comparison of graphs created with punctuation included and excluded. The aim of the thesis is to contribute to a better understanding of the role punctuation plays in text structure and to what extent it affects the properties of language networks. I chose this topic because I am interested in data analysis and statistical regularities that can be uncovered in natural language. What I find particularly interesting about this topic is that even ordinary texts contain features that can be captured and compared using appropriate analytical tools.

Keywords: word network, punctuation, degree distribution, power law, Zipf-Mandelbrot, clustering, Python, text analysis

Obsah

Úvod	1
1 Teoretický základ	2
1.1 Teória grafov	2
1.1.1 Základné vlastnosti vrcholov a hrán	2
1.1.2 Klasterizačný koeficient	3
1.1.3 Distribúcia stupňov vrcholov	3
1.1.4 Najkratšie cesty a malý svet	3
1.2 Modely sietí	3
1.2.1 Náhodná sieť	3
1.2.2 Bezškálová sieť a mocninový zákon	4
1.2.3 Barabási-Albertov model	4
1.2.4 Dorogovtsev-Mendesov model	4
1.3 Slovné siete	4
1.3.1 Typy slovných sietí	4
1.3.2 Vlastnosti pozičných slovných sietí	5
1.3.3 Vplyv interpunkcie na slovnú sieť	5
1.4 Rank-frekvenčné rozdelenie a Zipfov zákon	5
1.4.1 Zipfov zákon	5
1.4.2 Zipf-Mandelbrotov model	6
1.5 Interpunkcia v písanom jazyku	6
Záver	7
Príloha A	9

Zoznam obrázkov

Zoznam tabuliek

Úvod

V súčasnosti, keď sa množstvo informácií prenáša najmä v digitálnej forme, sa strojová analýza textov stáva dôležitou súčasťou výskumu v oblasti spracovania prirodzeného jazyka. Jedným z menej preskúmaných, no zaujímavých aspektov textovej analýzy je interpunkcia. Napriek tomu, že ju vnímame predovšetkým ako gramatickú konvenciu, interpunkcia aktívne ovplyvňuje aj štruktúru a hlavne zrozumiteľnosť textu.

Kapitola 1

Teoretický základ

V tejto kapitole predstavíme základné pojmy a koncepty, ktoré tvoria teoretický rámec pre analýzu interpunkčných znamienok v slovných sieťach. Najprv sa venujeme teórii grafov a základným metráм sietí, následne modelom bezškálových sietí a ich vlastnostiam.

1.1 Teória grafov

Graf G je usporiadaná dvojica $G = (V, E)$, kde V je množina vrcholov (uzlov) a $E \subseteq V \times V$ je množina hrán reprezentujúcich vzťahy medzi vrcholmi [1]. V tejto práci pracujeme výhradne s *jednoduchými neorientovanými grafmi* – grafmi bez slučiek a násobných hrán, v ktorých hrana (u, v) nemá určený smer.

1.1.1 Základné vlastnosti vrcholov a hrán

Stupeň vrchola $\deg(v)$ udáva počet hrán incidentných s vrcholom v . Celkový počet hrán v grafe súvisí so stupňami vrcholov vzťahom

$$|E| = \frac{1}{2} \sum_{i=1}^n \deg(v_i), \quad (1.1)$$

kde $n = |V|$. **Priemerný stupeň** uzla je potom

$$\langle k \rangle = \frac{2|E|}{n}. \quad (1.2)$$

Hustota grafu vyjadruje, akú časť z maximálneho možného počtu hrán sieť obsahuje:

$$D = \frac{2|E|}{n(n-1)}. \quad (1.3)$$

Hodnota $D = 1$ zodpovedá úplnému grafu, $D \rightarrow 0$ riedkej sieti. Slovné siete sú typicky extrémne riedke, s hustotou rádovo 10^{-3} až 10^{-4} .

1.1.2 Klasterizačný koeficient

Klasterizačný koeficient meria, do akej miery sú susedia daného vrchola navzájom prepojení – teda ako veľmi sú lokálne skupiny uzlov tranzitívne uzavreté[2]. Lokálny klasterizačný koeficient vrchola v je definovaný ako

$$C_v = \frac{2|\{(u, w) \in E : u, w \in \mathcal{N}(v)\}|}{\deg(v)(\deg(v) - 1)}, \quad (1.4)$$

kde $\mathcal{N}(v)$ je množina susedov vrchola v . Priemerný klasterizačný koeficient celého grafu je

$$C = \frac{1}{n} \sum_{i=1}^n C_{v_i}. \quad (1.5)$$

1.1.3 Distribúcia stupňov vrcholov

Distribúcia stupňov $P(k)$ udáva pravdepodobnosť, že náhodne vybraný vrchol má práve k susedov:

$$P(k) = \frac{N_k}{n}, \quad (1.6)$$

kde N_k je počet vrcholov so stupňom k . Priemerný stupeň možno vyjadriť ako

$$\langle k \rangle = \sum_{k=0}^{\infty} k P(k). \quad (1.7)$$

Tvar distribúcie stupňov je jednou z najdôležitejších charakteristík siete a odlišuje rôzne typy sietí od seba.

1.1.4 Najkratšie cesty a malý svet

Priemerná dĺžka najkratšej cesty (ASPL, *average shortest path length*) medzi všetkými dvojicami vrcholov je

$$L = \frac{1}{n(n-1)} \sum_{\substack{i,j=1 \\ i \neq j}}^n d(v_i, v_j), \quad (1.8)$$

kde $d(v_i, v_j)$ je počet hrán najkratšej cesty medzi vrcholmi v_i a v_j [3].

Sieť sa nazýva *small-world* (malý svet), ak má súčasne krátku priemernú cestu porovnateľnú s náhodným grafom rovnakej veľkosti a hustoty, $L \approx L_{\text{rand}} = \ln N / \ln \langle k \rangle$, a zároveň výrazne vyšší klasterizačný koeficient, $C \gg C_{\text{rand}} = \langle k \rangle / N$.

1.2 Modely sietí

1.2.1 Náhodná sieť

Klasický model náhodnej siete Erdősa a Rényiho $G(n, p)$ generuje sieť s n vrcholmi tak, že každá z $\binom{n}{2}$ možných hrán existuje nezávisle s pravdepodobnosťou p .

1.2.2 Bezškálová sieť a mocninový zákon

Mnohé reálne siete – internet, sociálne siete, biologické siete, ale aj slovné siete – vykazujú rozdelenie stupňov vrcholov podľa *mocninového zákona*:

$$P(k) \sim k^{-\gamma}, \quad (1.9)$$

kde γ je škálovací exponent. Na rozdiel od Poissonovho rozdelenia, ktoré má charakteristickú škálu okolo $\langle k \rangle$, mocninové rozdelenie nemá charakteristickú hodnotu – existujú uzly s ľubovoľne vysokým stupňom (*hubs*). Preto sa takéto siete nazývajú bezškálové (*scale-free*).

V log-log grafe mocninový zákon produkuje priamku so smernicou $-\gamma$, čo umožňuje vizuálne aj analytické overenie tejto vlastnosti.

1.2.3 Barabási-Albertov model

Najznámejší mechanizmus vzniku bezškálových sietí je preferenčné pripájanie zavedené Barabásim a Albertom. Nový uzol sa pripojí k existujúcemu uzlu i s pravdepodobnosťou úmernou jeho stupňu:

$$\Pi(k_i) = \frac{k_i}{\sum_j k_j}. \quad (1.10)$$

Výsledná distribúcia stupňov sleduje mocninový zákon s $\gamma = 3$.

1.2.4 Dorogovtsev-Mendesov model

Model Dorogovtseva a Mendesa (DM) je rastový model navrhnutý špeciálne na modelovanie slovných sietí. Začína trojuholníkom (kompletný graf na troch vrchoch) a každý nový vrchol sa pripojí k obom koncovým bodom náhodne zvolenej existujúcej hrany, čím vždy vznikne nový trojuholník. Po t krokoch má sieť $N(t) = t + 2$ vrcholov a $E(t) = 2t + 1$ hrán.

1.3 Slovné siete

Slovné siete predstavujú grafovú reprezentáciu jazyka, kde vrcholy zodpovedajú slovám a hrany vyjadrujú vzájomné vzťahy medzi nimi. Podľa toho, aké vzťahy hrany kódujú, rozlišujeme viacero typov slovných sietí.

1.3.1 Typy slovných sietí

Sémantické siete spájajú slová na základe ich významovej podobnosti (synonymá, asociácie). Takéto siete nie sú bezškálové.

Syntaktické siete spájajú slová, medzi ktorými existuje syntaktická závislosť – napríklad medzi slovesom a jeho podmetom alebo predmetom.

Pozičné siete susednosti (*word adjacency networks*) sú typom syntaktickej siete, kde hrana existuje medzi každými dvoma slovami, ktoré v texte stoja bezprostredne za sebou. Teda tokeny w_i a w_{i+1} sú spojené hranou bez ohľadu na ich gramatickú funkciu.

1.3.2 Vlastnosti pozičných slovných sietí

Pozičné slovné siete vykazujú niekoľko charakteristických vlastností:

- **Bezškálovosť:** Distribúcia stupňov vrcholov sleduje mocninový zákon (1.9) s $\gamma \approx 1.5$ – 2.7 . Slová s vysokým stupňom (huby) zodpovedajú gramatickým funkčným slovám – členom, spojкам, predložkám – ktoré sa vyskytujú v rôznych kontextoch.
- **Small-world štruktúra**
- **Hierarchická štruktúra:** Klasterizačný koeficient klesá so stupňom uzla podľa $C(k) \sim k^{-\delta}$, kde $\delta > 0$. Huby majú nízky clustering a prepájajú rôzne komunity slov, zatiaľ čo periférne uzly sú súčasťou tesných lokálnych skupín.
- **Disasortatívnosť:** Uzly s vysokým stupňom sa spravidla spájajú s uzlami s nízkym stupňom (záporný koeficient asortatívnosti $r < 0$).

1.3.3 Vplyv interpunkcie na slovnú sieť

Keď sú interpunkčné znamienka zahrnuté do slovnej siete ako plnohodnotné uzly, ich frekventovaný výskyt spôsobuje, že sa stávajú hubmi s vysokým stupňom.

1.4 Rank-frekvenčné rozdelenie a Zipfov zákon

1.4.1 Zipfov zákon

Jedným z najznámejších empirických zákonov kvantitatívnej lingvistiky je *Zipfov zákon* [4]. Ak zoradíme slová textu podľa frekvencie zostupne a pridáme im poradie (rank) $R = 1, 2, 3, \dots$, potom platí

$$P(R) \sim R^{-\alpha}, \quad (1.11)$$

kde $P(R)$ je relatívna frekvencia slova s poradím R a $\alpha \approx 1$ pre prirodzený jazyk. V log-log grafe sa závislosť $P(R)$ zobrazuje ako priamka so smernicou $-\alpha$.

1.4.2 Zipf-Mandelbrotov model

Čistý Zipfov zákon nie dobre opisuje rozdelenie pri nízkych rankoch (najfrekventovanejšie slová), kde empirické dáta systematicky odchyľujú od priamky. Mandelbrot navrhol rozšírenie

$$P(R) = A(R + c)^{-\alpha}, \quad (1.12)$$

kde $c \geq 0$ je parameter posunu a A je normalizačná konštanta. Pre $c = 0$ sa model redukuje na čistý Zipfov zákon. Parameter c meria mieru zakrivenia krivky pri nízkych rankoch – čím väčší c , tým viac sa distribúcia odchyľuje od čistého mocninového zákona v oblasti najčastejších slov.

1.5 Interpunkcia v písanom jazyku

Z lingvistického hľadiska môžeme interpunkčné znamienka rozdeliť podľa ich funkcie na:

- **Ukončovacie:** bodka (.), otáznik (?), výkričník (!), elipsa (...) – signalizujú koniec vetného celku;
- **Oddeľovacie:** čiarka (,), bodkočiarka (;), dvojbodka (:) – oddeľujú vetné členy a vedľajšie vety;
- **Uzatváracie:** úvodzovky, zátvorky – ohraničujú vložené časti textu;
- **Iné:** pomlčka, lomka, spojovník a ďalšie.

Záver

Literatúra

- [1] Reinhard Diestel. *Graph Theory*. Springer, 5 edition, 2017.
- [2] Mária Markošová. Dynamika sietí. In Vladimír Kvasnička, Jiří Pospíchal, Pavol Návrát, and Branislav a Peter Trebatický Lacko, editors, *Umelá inteligencia a kognitívna veda II*, pages 321–377. Slovenská technická univerzita, Bratislava, 2010.
- [3] Ramon Ferrer i Cancho and Richard V. Solé. The small world of human language. *Proceedings of the Royal Society B*, pages 2261–2265, 2001.
- [4] Andrzej Kulig, Jarosław Kwapiń, Tomasz Stanisław, and Stanisław Drożdż. In narrative texts punctuation marks obey the same statistics as words. *Information Sciences*, 375:98–113, 2017.

Príloha A: obsah elektronickej prílohy

V elektronickej prílohe sa nachádza kompletný zdrojový kód webovej aplikácie vytvorenej v Pythone pomocou frameworku Flask. Príloha obsahuje aj export PostgreSQL databázy a návod na spustenie aplikácie.