

Model distribúcie interpunkčných znamienok v rôznych textoch

Bc. Filip Valíček

Školiteľka: doc. RNDr. Mária Markošová, PhD.

Motivácia a cieľ práce

Motivácia

- ▶ Prirodzený jazyk obsahuje pravidelnosti, ktoré sa dajú skúmať pomocou dátovej a štatistickej analýzy
- ▶ Text možno reprezentovať ako sieť, čím sa otvára možnosť sledovať jeho štruktúru z iného než čisto lingvistického pohľadu
- ▶ Jazykové siete vykazujú vlastnosti, ktoré sú zaujímavé z hľadiska teórie grafov a komplexných systémov
- ▶ Interpunkcia býva v mnohých prístupoch zanedbávaná, hoci môže niesť dôležitú štrukturálnu informáciu
- ▶ Jazykové porovnanie: EN / DE / FR

Cieľ práce

- ▶ Vytvoriť slovné siete z literárnych textov na základe susednosti slov v texte
- ▶ Porovnať siete vytvorené so započítaním interpunkcie a bez nej
- ▶ Analyzovať vybrané charakteristiky, hlavne distribúciu stupňov uzlov, clustering a organizáciu siete
- ▶ Porovnať rovnaké literárne diela v rôznych jazykových mutáciách a identifikovať rozdiely v ich štruktúre
- ▶ Navrhnuť a implementovať interaktívnu aplikáciu, ktorá umožní texty spracovať, analyzovať a vizualizovať výsledky


Slovná susednostná sieť (Word Adjacency Network)

Uzol = unikátny token , Hrana = susednosť v texte

Príklad: "the cat sat on the mat" → hrany: (the,cat),(cat,sat),(sat,on),(on,the),(the,mat)

Vlastnosti

- Neorientovaný graf
- Váha hrany vyjadruje počet spoločných výskytov dvojice susedných prvkov v texte
- Slučky (slovo susedí samo so sebou) sa vynechávajú
- Sieťové metriky sa počítajú na najväčšej súvislej komponente (LCC)
- Interpunkcia je reprezentovaná tokenmi #dot, #com, #qu, #ex, #ell



Kód – graph_builder.py

```
def build_graph(tokens, weighted=True):
    G = nx.Graph()
    for i in range(len(tokens) - 1):
        u, v = tokens[i], tokens[i+1]
        if u == v:
            continue
        if G.has_edge(u, v):
            if weighted:
                G[u][v]["weight"] += 1
        else:
            G.add_edge(u, v, weight=1)
    return G
```

Metodológia analýzy

P(k) – Distribúcia stupňov uzlov

- Ukazuje, koľko susedov majú jednotlivé uzly v sieti
- Väčšina slov je prepojená len s malým počtom iných slov
- Malý počet veľmi častých slov tvorí silno prepojené uzly siete
- Rozdelenie má približne mocninový priebeh $P(k) \sim k^{-\gamma}$
- Exponent γ je odhadovaný lineárnym fitom v log-log priestore

Zipf / Zipf-Mandelbrot

- Opisuje vzťah medzi poradím slova a jeho frekvenciou v texte
- Najčastejšie slová sa vyskytujú výrazne častejšie než zvyšok slovnej zásoby
- Zipfov zákon zachytáva základný mocninový pokles frekvencie s rastúcim poradím
- Zipf-Mandelbrotov model spresňuje tento priebeh najmä v oblasti najfrekventovanejších slov - dopĺňa parameter c , ktorý koriguje odchýlky pri nízkych rankoch

C(k) – Klasterizačný koeficient v závislosti od stupňa

- Pravdepodobnosť, že dvaja susedia uzla sú navzájom spojení hranou
- Sleduje sa v závislosti od stupňa uzla, teda ako sa mení klasterizácia s rastúcim k
- V jazykových sieťach má $C(k)$ klesajúci priebeh
- Tento priebeh možno aproximovať vzťahom $C(k) \sim k^{-\delta}$

ASPL, priemer, asortativita

- Priemerná najkratšia cesta L vyjadruje, ako ďaleko sú od seba uzly v sieti
- Priemerný stupeň $\langle k \rangle$ opisuje priemerný počet susedov jedného uzla
- Asortativita r meria, či sa uzly pripájajú k uzlom s podobným stupňom
- Záporné r naznačuje, že huby sa spájajú skôr s menej prepojenými uzlami
- Malá hodnota L vzhľadom na veľkosť siete podporuje interpretáciu siete ako malého sveta

Implementácia

Funkcionalita

- Stiahnutie textov z Project Gutenberg
- Tokenizácia: slová + interpunkcia
- Stavba siete
- Charakteristika siete/grafu
- $P(k)$: log-bin OLS, MLE+KS, dvojrežimový fit
- Zipf / Zipf-Mandelbrot fitovanie
- $C(k)$ klasterizácia vs. stupeň
- Porovnanie jazykových variantov
- Modely sietí: ER, BA, WS, PowerlawCluster
- Export grafu do CSV + Vizualizácia grafu

Python, Matplotlib, Tkinter, scipy

Architektúra

```
app.py          ← GUI (Tkinter + Matplotlib TkAgg)
├── src/downloader.py    ← Project Gutenberg HTTP
├── src/preprocessor.py   ← tokenizácia
├── src/graph_builder.py
├── src/analyzer.py       ←  $P(k)$ ,  $C(k)$ , ASPL,  $r$ 
├── src/models.py         ← Zipf, ZM, powerlaw fit
└── src/visualizer.py    ← Matplotlib

main.py         ← CLI
data/texts/     ← lokálne uložené texty
results/data/   ← CSV exporty
```

Stiahnutie textov z Project Gutenberg

Text source

☒ Local file ☐ Project Gutenberg

Active source: Local file

Local file

Crime_and_Punishment.txt

Browse...

Title (for plots & exports):

Crime and Punishment

Language: EN (for preprocessing)

Project Gutenberg catalog

Language: EN

Book:

Crime and Punishment (EN) (Fyodor Dostoyevskiy)

or Gutenberg ID: 2554 Downloaded

Load

Toto slúži na výber zdroja textu, s ktorým bude aplikácia pracovať.

- V časti Text source si používateľ zvolí, či chce pracovať s lokálnym súborom alebo s textom z Project Gutenberg
- Active source zobrazuje, ktorý zdroj je momentálne aktívny a z ktorého sa bude text načítavať
- V sekcii Local file možno vybrať vlastný .txt súbor z počítača
- Title určuje názov, ktorý sa bude používať v grafoch, tabuľkách a exportoch
- Language určuje jazyk textu pre potreby preprocessingu a spracovania
- V Project Gutenberg catalog možno vybrať text buď zo zoznamu pripravených diel, alebo zadáním konkrétneho Gutenberg ID

Tokenizácia

Punctuation marks

All None Kulig Sent. Basic

Sentence boundaries

- ☒ Period #dot .
- ☒ Question mark #qu ?
- ☒ Exclamation #ex !
- ☒ Ellipsis #ell ...

Within sentence

- ☒ Comma #com ,
- ☒ Semicolon #scol ;
- ☒ Colon #col :

Dashes

- ☒ Em-dash #emdash —
- ☒ En-dash #ndash —
- ☒ Hyphen #hyph -

Quotation & enclosing

- ☒ Quotation marks #quot " "
- ☒ Apostrophe #apos '
- ☒ Guillemets #guill « »
- ☒ Parentheses #par ()
- ☒ Square brackets #brk []

Other

- ☒ Slash #slash /
- ☒ Asterisk #ast *
- ☒ Underscore #und _
- ☒ Curly braces #curly { }

* counted in summary; graph support coming later

Show summary

Top 20 most frequent tokens

Rank	Token	Count	%
1	#com	16,041	6.29%
2	#dot	9,757	3.83%
3	#quot	7,911	3.10%
4	the	7,827	3.07%
5	and	6,960	2.73%
6	to	5,273	2.07%
7	he	4,775	1.87%
8	a	4,597	1.80%
9	i	4,405	1.73%
10	#apos	4,314	1.69%
11	you	4,048	1.59%
12	of	3,810	1.49%
13	it	3,449	1.35%
14	that	3,293	1.29%
15	in	3,195	1.25%
16	was	2,826	1.11%
17	#ex	2,363	0.93%
18	#qu	2,277	0.89%
19	his	2,116	0.83%
20	at	2,067	0.81%

Punctuation counts

Token	Name	Symbol	Count	Per 1k words	Selected
#dot	Period	.	15,832	75.8	yes
#qu	Question mark	?	2,277	10.9	yes
#ex	Exclamation	!	2,363	11.3	yes
#ell	Ellipsis	...	1,767	8.5	yes
#com	Comma	,	16,041	76.8	yes
#scol	Semicolon	;	1,046	5.0	yes
#col	Colon	:	235	1.1	yes
#emdash	Em-dash	—	17	0.1	yes
#ndash	En-dash	—	0	0.0	yes
#hyph	Hyphen	-	126	0.6	yes
#quot	Quotation marks	" "	7,911	37.9	yes
#apos	Apostrophe	'	4,314	20.7	yes
#guill	Guillemets	« »	0	0.0	yes
#par	Parentheses	()	314	1.5	yes
#brk	Square brackets	[]	12	0.1	yes
#slash	Slash	/	0	0.0	yes
#ast	Asterisk	*	31	0.1	yes
#und	Underscore	_	506	2.4	yes
#curly	Curly braces	{ }	0	0.0	yes

- Text sa rozkladá na slová a voliteľne aj na interpunkčné tokeny
- Interpunkcia je reprezentovaná špeciálnymi značkami, napr. #dot, #com, #qu
- Používateľ si vyberá, ktoré typy interpunkcie vstupujú do analýzy
- K dispozícii sú viaceré prednastavené režimy tokenizácie

Sieťové metriky


Text statistics

Metric	Value
Characters (total)	1,135,115
Characters (no spaces)	927,397
Words (total)	208,782
Words (unique)	9,403
Sentences (estimated)	16,151
Lines	22,066
Paragraphs (estimated)	17,982
Type-Token Ratio	0.0450

Graph	
	With / Without
Nodes	9678 / 9606
Edges	72693 / 77614
Avg. degree <k>	15.02 / 16.16
Density	0.001552 / 0.001682
LCC fraction	1.0000 / 1.0000
Avg. clustering C	0.6190 / 0.5586

- Sleduje sa počet znakov, slov, jedinečných slov, viet, odsekov a type-token ratio
- Type-token ratio vyjadruje pomer počtu rôznych slov k celkovému počtu slov
- Nodes (N) – počet uzlov siete, teda počet rôznych slov a prípadne aj interpunkčných tokenov
- Edges (E) – počet hrán medzi uzlami, teda počet rôznych susedností v texte
- Avg. degree <k> – priemerný počet susedov jedného uzla
- Density – hustota siete, teda pomer existujúcich hrán ku všetkým možným hranám
- Avg. clustering C – priemerná miera lokálneho prepojenia susedov uzlov


Rozdelenie stupňov $P(k)$ (20%-80% fit)



Kľúčové zistenia

- $P(k)$ sa vyhodnocuje v log-log priestore
- Dáta sú logaritmicky binované (25 binov)
- Fit sa vykonáva len na strednej časti distribúcie, konkrétne v intervale 20–80 % binned bodov
- Exponent γ je odhadovaný lineárnou regresiou nad vybraným intervalom
- V oboch prípadoch vychádza približne mocninový priebeh distribúcie
- Interpunkcia nemení charakter distribúcie zásadne


Rozdelenie stupňov $P(k)$ - najdlhší monotónne klesajúci úsek



Kľúčové zistenia

- Táto distribúcia stupňov bola fitovaná na najdlhšom monotónne klesajúcom úseku log-binovaných dát
- Interval začína približne pri $k \approx 4.3$ a siaha až po vysoké stupne
- Pre sieť s interpunkciou vychádza exponent približne $\gamma \approx 2.04$, pre sieť bez interpunkcie $\gamma \approx 1.98$
- Na rozdiel od fixného intervalu 20–80 % sa tu fit neviaže na preddefinovanú strednú časť dát


Rozdelenie stupňov $P(k)$ – KS vzdialenosť



Kľúčové zistenia


- Pri tejto metóde sa power-law fit neaplikuje na celú distribúciu, ale len na vypočítaný interval $k \in [k_{\min}, k_{\max}]$
- Hodnota $k_{\min}$ je určená minimalizáciou Kolmogorov-Smirnovovej vzdialenosti (KS), teda hľadá sa taký začiatok chvosta, od ktorého model sedí najlepšie
- Exponent γ sa tu už neodhadzuje lineárnou regresiou v log-log priestore, ale pomocou odhadu maximálnej vierohodnosti (MLE)
- Horná hranica $k_{\max}$ oddeľuje plochý koniec distribúcie, ktorý by mohol výsledok skresľovať
- Pre sieť s interpunkciou vychádza interval približne $k \in [38, 127]$, pre sieť bez interpunkcie $k \in [44, 159]$
- Odhadnutý exponent je v oboch prípadoch veľmi podobný, približne $\gamma \approx 2.09$

Rozdelenie stupňov $P(k)$ – Full auto two-regime fit




Kľúčové zistenia

- Tu je distribúcia $P(k)$ modelovaná dvojrežimovým mocninovým fitom s pevným breakpointom k^*
- Na odhad exponentov bol použitý odhad maximálnej vierohodnosti (MLE), nie lineárna regresia
- Dolný režim ($k < k^*$) vychádza v oboch prípadoch veľmi podobne, približne $\gamma_1 \approx 1.65$
- Horný režim ($k \geq k^*$) je výrazne strmší, približne $\gamma_2 \approx 3.15$
- Výsledok naznačuje, že distribúciu nie je vhodné opisovať jedným exponentom v celom rozsahu stupňov
- Interpunkcia má len minimálny vplyv na hodnoty oboch exponentov, keď je breakpoint zvolený pevne




Rozdelenie stupňov $P(k)$ - Two-regime fit s pevným breakpointom



Kľúčové zistenia

- V tomto prístupe sa automaticky určovali všetky tri hranice fitu: $k_{\min}$, k^* aj $k_{\max}$
- Aj tu bol použitý MLE, pričom fit sa vykonával oddelene v dvoch režimoch
- Pre obe siete vyšlo $k_{\min} = 1$, breakpoint približne $k^* = 4$ a horná hranica chvosta $k_{\max} \approx 127 / 159$
- Dolný režim ostáva stabilný na hodnote $\gamma_1 \approx 1.65$, čo potvrdzuje robustnosť tej nízkostupňovej časti distribúcie
- Horný režim vychádza miernejší než pri pevnom breakpointe, približne $\gamma_2 \approx 2.84$ s interpunkciou a $\gamma_2 \approx 2.77$ bez interpunkcie

Zipf / Zipf-Mandelbrot




Kľúčové zistenia

- Zipfov zákon opisuje vzťah medzi poradím slov a v texte a jeho frekvenciou výskytu
- Najčastejšie slová sa v texte objavujú výrazne častejšie než slová s vyšším poradím, pričom frekvencia približne klesá podľa mocninového zákona
- Zipf Mandelbrot model tento vzťah rozširuje o parameter c , ktorý koriguje priebeh distribúcie pri najnižších rankoch
- Vďaka tomu dokáže lepšie opísať oblasť najfrekventovanejších slov, kde čistý Zipfov model často nestačí

Kľúčový výsledok: parameter c v Zipf-Mandelbrot je nižší KEĎ je interpunkcia zahrnutá – dokázanie toho, čo sa píše v článku od Kuliga

Klasterizačný koeficient $C(k)$



- $C(k)$ sleduje, ako sa klasterizácia mení so stupňom uzla
- V oboch verziách siete má $C(k)$ klesajúci priebeh, čo naznačuje prítomnosť hierarchickej organizácie
- Fit bol realizovaný na log-binovaných dátach v log-log priestore
- Pre sieť s interpunkciou vychádza približne $\delta \approx 0.54$, pre sieť bez interpunkcie $\delta \approx 0.46$
- Sieť s interpunkciou teda vykazuje o niečo strmší pokles klasterizácie s rastúcim stupňom

Export siete do CSV


```
Source,Target,Weight
crime,and,5
crime,#quot,2
crime,tiny,1
crime,be,1
crime,the,11
crime,#com,9
crime,from,1
crime,a,9
crime,#ell,1
crime,first,3
crime,#ex,4
crime,calculated,1
crime,#scol,3
crime,that,1
crime,has,1
crime,is,4
crime,as,1
crime,#dot,8
crime,all,1
crime,will,2
crime,in,2
crime,of,1
crime,about,2
crime,on,2
crime,#apos,1
crime,to,3
crime,#qu,6
crime,any,1
crime,every,1
crime,your,2
crime,committed,1
crime,by,2
crime,what,1
```

do CSV

- Výsledná slovná sieť je exportovaná vo formáte Source, Target, Weight
- Source a Target predstavujú dvojicu susedných tokenov v texte
- Weight vyjadruje, koľkokrát sa daná susednosť v texte vyskytla
- Slová aj interpunkčné znamienka sú reprezentované rovnakým spôsobom ako uzly siete
- Interpunkcia je zapísaná pomocou špeciálnych tokenov, napr. #dot, #com, #qu, #quot

Porovnanie rozdelenia stupňov s modelovými sieťami

Degree Distributions of Models — Crime and Punishment




Empirical G1 = with punctuation | Empirical G2 = without punctuation

Metrics

Model	N	E	Density	Clustering	Slope	Closest
Empirical G1	9,678	72,693	0.0016	0.6190	-2.01	—
Empirical G2	9,606	77,614	0.0017	0.5586	-1.96	—
Barabasi-Albert	9,678	67,697	0.0014	0.0088	-2.87	—
Powerlaw Cluster	9,678	67,659	0.0014	0.0845	-2.76	G1, G2
Dorogovtsev-Mendes	9,678	19,353	0.0004	0.7404	-2.67	—

- Porovnanie empirických sietí so syntetickými modelmi prebieha cez $P(k)$ a ďalšie metriky
- Empirical G1 = s interpunkciou, Empirical G2 = bez interpunkcie
- Porovnávané modely:
 - Barabási-Albert
 - Powerlaw Cluster
 - Dorogovtsev-Mendes

Porovnanie jazykových mutácií – Alice in Wonderland



- Porovnávajú sa tri jazykové verzie toho istého diela: **EN, DE a FR**
- $P(k)$ má vo všetkých troch jazykoch podobný priebeh ($\gamma \approx 1.67\text{--}1.77$)
- $C(k)$ naznačuje hierarchickú organizáciu, najvýraznejšiu vo FR ($\delta \approx 0.53$)
- Najväčší rozdiel sa objavuje v parametroch Zipf-Mandelbrota, najmä v c
- ZM c je výrazne nižšie v EN než v DE a FR
- EN má hustejšiu sieť a vyšší priemerný stupeň
- Jazykové mutácie si zachovávajú podobný globálny charakter, ale líšia sa v detailoch štruktúry

Zdroje

Literatúra

- [1] Reinhard Diestel. Graph Theory. Springer, 5 edition, 2017.
- [2] Mária Markošová. Dynamika sietí. Umelá inteligencia a kognitívna veda II, strany 321–377. Slovenská technická univerzita, Bratislava, 2010.
- [3] Ramon Ferrer i Cancho and Richard V. Solé. The small world of human language. Proceedings of the Royal Society B, pages 2261–2265, 2001.
- [4] Andrzej Kulig, Jarosław Kwapiń, Tomasz Stanis, and Stanisław Drożdż. In narrative texts punctuation marks obey the same statistics as words. Information Sciences, 375:98–113, 2017

Ďakujem za pozornosť!